

Universidad del Valle de Guatemala
Facultad de Ingeniería
Data Science



“Proyecto 2: Informe Final”

Davis Roldán 22672
Andy Fuentes 22944
Gabriel Paz 221087
Jose Marchena Molina

18 de noviembre del 2025, Guatemala de la Asunción

Introducción general del proyecto:

El presente proyecto aborda el problema de la clasificación de la etiología de trombos en accidentes cerebrovasculares isquémicos, utilizando imágenes histopatológicas de alta resolución (*Whole Slide Images, WSI*) provenientes del reto Mayo Clinic STRIP AI Challenge. El objetivo global es distinguir entre dos orígenes principales de los coágulos: cardioembólico (CE) y aterosclerosis de arteria grande (LAA), ya que esta decisión influye directamente en el tratamiento médico posterior (por ejemplo, uso de anticoagulantes vs. antiagregantes).

Desde la perspectiva de ciencia de datos, el problema presenta varias dificultades: las WSI son imágenes muy grandes y heterogéneas, existe desbalance entre las clases y las etiquetas están disponibles principalmente a nivel de paciente, no de parche individual. Esto exige modelos capaces de manejar datos de alta dimensión, aprender a partir de etiquetas débiles y, al mismo tiempo, mantener cierta interpretabilidad para un contexto clínico.

A lo largo del proyecto se trabajó en tres fases complementarias. En la Fase 1 se realizó un análisis exploratorio de datos (EDA) que permitió comprender la estructura del dataset, la distribución de las clases y propiedades relevantes de las imágenes (cobertura de tejido, enfoque, canales de color y tinciones H&E). En la Fase 2 se desarrollaron y evaluaron distintos modelos de aprendizaje profundo, principalmente una CNN basada en ResNet18 y un enfoque de Multiple Instance Learning (MIL) a nivel de paciente. Finalmente, en la Fase 3 se integraron estos modelos dentro de una aplicación interactiva tipo dashboard, que permite configurar experimentos, cargar nuevas láminas y visualizar métricas y predicciones de forma intuitiva.

En conjunto, el proyecto recorre el ciclo completo de un caso típico de Data Science: desde la exploración y preparación de los datos, pasando por el diseño y evaluación de modelos, hasta la implementación de una herramienta práctica que podría servir como base para un sistema de apoyo a la decisión clínica.

Fase 1 – Análisis Exploratorio de Datos (EDA):

Introducción

Los avances en la ciencia de datos han permitido abordar problemáticas cada vez más complejas de diversas áreas de estudio. Con modelos convolucionales y redes neuronales, el análisis de imágenes y estadísticas se ha convertido en una realidad de nuestro tiempo, con modelos incluso capaces de realizar diagnósticos médicos con una alta precisión.

El conjunto de datos Mayo Clinic STRIP AI Challenge provee imágenes digitales de alta calidad de WSI (Whole Slided Image) correspondientes a la presencia de coágulos en el cerebro de diferentes pacientes. La clasificación del origen de estos trombos o trombos es tarea de los médicos y expertos en patología para guiar el tratamiento a futuro, sin embargo, la identificación del origen posee alta incertidumbre.

Por tanto, en este proyecto, se aplicarán los conocimientos adquiridos en este curso para la implementación de modelos de aprendizaje profundo con el fin de realizar un diagnóstico de las imágenes WSI mencionadas, para poder clasificar el origen de un accidente cardiovascular isquémico

Planteamiento de problemática

La problemática radica en la clasificación binaria de dos posibles orígenes de un coágulo cerebral. En la práctica, se obtienen capturas WSI que permiten observar la presencia de fibrina y células rojas en el cerebro para localizar e identificar el coágulo por sus manifestaciones en las siguientes 2 categorías

- Cardioembólico (CE): Implica un origen del corazón, que puede requerir el uso de anticoagulantes
- Ateroesclerosis de arteria grade (LA): formado en las arterias principales, y puede sugerir el tratamiento de antiagregantes

Según estudios clínicos e imagenológicos, el origen de un trombo puede quedar indeterminado o tener una alta incertidumbre. Por tanto, se plantea el uso de redes neuronales y modelos de aprendizaje profundo para poder realizar esta clasificación.

Objetivos

Para esta entrega, se tiene como objetivo desarrollar un análisis exploratorio de datos (EDA) sobre las imágenes histopatológicas de trombos, con el fin de identificar patrones y características relevantes que preparen la base para un modelo de clasificación CE vs LAA.

Objetivos específicos

1. Describir la estructura del dataset, incluyendo número de casos, distribución por clase y metadatos asociados.
2. Implementar técnicas de preprocesamiento para filtrar tiles no informativos (fondo, blur, bajo tejido) y normalizar la tinción.
3. Explorar métricas básicas de color, textura y cobertura de tejido para cada clase.
4. Visualizar los datos mediante histogramas, diagramas de caja y bigote y reducciones de dimensionalidad (UMAP/t-SNE) para detectar posibles separaciones entre clases.

Investigación Preliminar

- ***Contexto Medico:***

El accidente cerebrovascular isquémico (ACV) ocurre cuando un coágulo interrumpe el flujo sanguíneo al cerebro. Existen varias causas, pero dos de las más frecuentes son: Cardioembólico (CE), que consiste en coágulos que se originan en el corazón, por ejemplo, a raíz de fibrilación auricular o insuficiencia cardíaca. Así como también Ateroesclerosis de arteria grande (LAA), donde trombos formados en arterias cerebrales principales debido a placas ateroscleróticas.

La distinción entre ambos es esencial, ya que determina el tratamiento: anticoagulación para CE vs. antiagregación y control de factores de riesgo para LAA.

- ***Imágenes histopatológicas:***

En el reto se utilizan Whole Slide Images (WSI) de trombos extraídos mediante trombectomía. Estas imágenes se obtienen con tinción Hematoxilina & Eosina (H&E), que resalta estructuras celulares:

- Hematoxilina: tiñe núcleos de color azul/púrpura.

- Eosina: tiñe citoplasma y componentes extracelulares de rosado.

- ***Relevancia del análisis computacional***

El análisis manual de WSI es complejo y requiere mucho tiempo de especialistas. Aquí entra la ciencia de datos, que nos permite implementar una forma estructurada de analizar y extraer información de estas imágenes

Por ejemplo, se considera el uso de fragmentación de las imágenes en tiles para su estudio, y el uso de técnicas de preprocesamiento y normalización para eliminar el ruido

También, esto facilita la extracción de características cuantitativas y la generación de representaciones que faciliten la clasificación con modelos de Vision por Computadora.

Descripción de los Datos

El conjunto de datos de entrenamiento consta 754 imágenes de WSI asociadas a un diagnóstico de un accidente cerebrovascular. La implementación se basa en 2 subconjuntos separados: las imágenes en sí, y la meta data o información asociada a ellas.

Metadata / Información adicional:


- **Image_id:** cadena de caracteres que identifica a una imagen, siendo una concatenación del id del paciente y del número de imagen
- **Center id:** número identificador del centro médico donde se realizó la toma el WSI
- **Patient Id:** cadena hexadecimal de 6 caracteres que identifica a los pacientes
- **Image Num:** cantidad de imágenes asociadas a un paciente, indexadas desde cero. Es decir, 0 significa una imagen, 1 significa 2 imágenes, etc.
- **Label:** clasificación del diagnóstico de origen del coágulo, como se mencionó anteriormente puede ser CE o LAA.

Como se puede observar, mucha de la información es identificadora y no realmente descriptiva, pues el análisis se realizará principalmente en las imágenes asociadas a un paciente.

En las numéricas, podemos ver que el identificador del centro médico es un número entero que varía entre 1 y 11, pero igualmente es parte de una asignación. Asimismo, el número de imágenes se mantiene en una media menor a 1, aunque existe un paciente con 4 imágenes asociadas a su diagnóstico.


	center_id	image_num
count	754.000000	754.000000
mean	7.115385	0.226790
std	3.504306	0.599046
min	1.000000	0.000000
25%	4.000000	0.000000
50%	7.000000	0.000000
75%	11.000000	0.000000
max	11.000000	4.000000

Con respecto a la clasificación de los diagnósticos, podemos observar el siguiente gráfico de barras, donde se puede observar que cerca de 500 observaciones (representativas del 70% de nuestro conjunto de datos) es perteneciente al diagnóstico CE, mientras 200 son de LAA.



Imágenes:

Las imágenes del conjunto de datos están identificadas por un nombre el cual es la concatenación del identificador de paciente con el número de imagen. Estas están en formato png con canales rojo, verde y azul.




Análisis exploratorio

En el manejo de imágenes, especialmente aquellos correspondientes a análisis de patologías, se consideran diferentes aspectos relevantes para el análisis de las muestras. A continuación, se muestra un análisis exploratorio de las fotografías del conjunto de datos con un enfoque en las tendencias y comportamientos de estas mismas

Cobertura de tejido


La cobertura de tejido indica que porcentaje de una imagen está compuesto por información relevante sobre el tejido. Dado que se manejan formatos PNG, la diferenciación con el fondo se puede realizar de manera sencilla



Es posible observar en las pruebas realizadas en 3 imágenes aleatoriamente elegidas, que la cobertura del tejido tiende a ser cercana al 60% dadas las medianas de los diagramas. Sin embargo, existen varias entradas con una muy baja cobertura de tan solo 30%.

Desenfoque




En visión por computadora, es también posible identificar el índice de desenfoque de una imagen, debido a que una imagen con bordes poco definidos puede conllevar a incertidumbre en las predicciones y una peor diferenciación de razgos. Utilizando el índice de varianza de desenfoque a partir del laplaciano de los canales de color, es posible observar la siguiente distribución.



El desenfoque de estas imágenes tiende a estar en su mayoría por encima del 1000. Para contextualizar esta métrica, valores superiores al 100 indican una alta definición y nitidez de bordes. Por tanto, se considera que estas imágenes tienen un alto índice de enfoque


Presencia en canales RGB

Considerando la distribución de frecuencia para los canales de rojo, verde y azul para las imágenes, podemos observar ciertos comportamientos interesantes. En la distribución de rojo, existe un sesgo hacia la derecha, lo cual muestra una acumulación de valores altos en este canal. Asimismo, el histograma de verde parece tener una moda más cercana al medio, lo que nos indica una distribución unimodal este canal. Por último, el azul parece ser más uniforme, con una presencia alta en todas las imágenes y muchas modas.



Presencia en canales Hematoxilina y Eosina


En el contexto de imágenes de patología, se puede hacer una correlación directa entre los canales azul y rojo con la presencia de los tintes de hematoxilina y eosina las cuales identifican la presencia de núcleo y cuerpo celular, respectivamente.



En las distribuciones obtenidas, es posible observar que muchas áreas tienen un bajo índice de estas dos métricas, estas podrían atribuirse al espacio vacío de las mismas imágenes, pues indican una falta completa de presencia celular. Asimismo, la mayor anchura de eosina representa la mayor cobertura de espacio del cuerpo celular comparado con su núcleo


En este caso, el enfoque debería de ser dirigido a los puntos e instancias atípicas de estos dos tintes, pues una distribución poco equivalente de estos puede ser utilizadas para detectar formas anormales de las células, organización de los tejidos o patrones de enfermedades.

En los diagramas de caja y bigotes evaluados en 3 imágenes aleatorias mostrados a continuación, se puede ver que hay una cierta concordancia entre ambas métricas. Usualmente con una mayor presencia de hematoxilina se puede esperar una correspondencia de eosina. También se puede observar que la distribución de los cuartiles tiende a ser poco equitativa en algunas imágenes, lo que nos puede ayudar a identificar problemas previos a evaluar una imagen.



Análisis correlacional

Por último, se considera un análisis correlacional de las diversas métricas evaluadas hasta el momento. Se puede observar una correlación presente entre los canales de color, especialmente entre verde y azul, lo cual se puede correlacionar con la presencia de los tintes mencionados anteriormente, así como con la intensidad de un pixel dado. También, la cobertura de tejido se ve relacionada con la nitidez de una imagen, lo cual nos indica que el contenido de tejido de una imagen tiende a tener alto enfoque una vez se presenta.



Conclusiones

Analisis Exploratorio

- Se desarrollo un pipeline de extracción de tiles informativos sobre la presencia del tejido y el enfoque o nitidez de las imágenes, en conjunto con información sobre la tinción en canales RGB y presencia de H&E (Hematoxilina y Eosina)
- Se observaron diferencias consistentes de cobertura y nitidez en las imagenes evaluadas
- La presencia de H&E concuerda con la distribución esperada, con cola a la derecha, así como también la dominancia de eosinofílicos en varias regiones

Implicaciones para modelado

- Además del uso de las imágenes en crudo, se considera la posibilidad y beneficio que conlleva el uso de características H&E, enfoque y cobertura para el muestreo de tiles en la futura etapa de modelado

Limitaciones y recomendaciones

- El conjunto de datos posee en ciertas instancias la falta de etiquetas para algunas de las imagenes
- El tamaño reducido del conjunto de imágenes con tan solo 750 entradas, algunas para pacientes recurrentes, puede llegar a ser una limitación a la hora de realizar modelos de aprendizaje profundo. Se recomienda el uso de aumentaciones de data para extrapolar la mayor cantidad de información del conjunto de datos.
- Las imágenes de muy alta resolución también pueden llegar a limitar el aprendizaje de un modelo, por lo que se reconoce el beneficio de aplicar previews o downsapling

Fase 2 – Modelado y evaluación de modelos

Introducción

Problema STRIP: etiología de stroke a partir de trombos

En un stroke isquémico el coágulo puede venir de distintos orígenes ya sea cardioembólico, ateroesclerótico de gran vaso, o causas poco comunes. Saber el origen ayuda a decidir la terapia secundaria como anticoagulación y antiagregación. Como ahora los coágulos se extraen con trombectomía mecánica, hay material para analizarlo con IA. El reto principal son las preparaciones histológicas son grandes, heterogéneas y no siempre están anotadas a nivel de parche.

Objetivos

General. Evaluar la viabilidad de un enfoque **MIL** con backbone **CNN (ResNet18)** para clasificar la etiología de trombos (CE vs LAA) en el reto STRIP usando bolsas de imágenes por paciente.

Específicos.

1. Preparar el pipeline: reducción de tamaño, agrupación por paciente (bolsas) y DataLoader compatible con MIL.
2. Implementar una CNN encoder-decoder con atención ligera y **CrossEntropy + Adam**.
3. Entrenar un prototipo en **5 épocas** para obtener curvas iniciales de pérdida y precisión.
4. Evaluar por paciente y por clase (matriz de confusión) e identificar riesgos de sobreajuste y sesgo de clase.
5. Proponer ajustes de regularización, balanceo y validación para la siguiente fase.

Investigación de Algoritmos

Algoritmos/modelos en problemas similares

1. Redes Neuronales Convolucionales (CNN) para histopatología

Las CNN tipo ResNet, DenseNet y EfficientNet se han usado mucho para clasificar tejidos en patología digital (cáncer, trombos, placas). Funcionan bien porque capturan texturas y patrones de color de fibrina, hematíes y leucocitos, que son justo las características que en stroke se asocian a distintos orígenes del trombo. Para nuestro reto STRIP se debe entrenar una CNN sobre parches del trombo para predecir el tipo de etiología.

2. **Multiple Instance Learning (MIL) / weakly supervised learning para whole-slide images**

En patología de coágulos pasa lo mismo que en otras WSI: tienes la etiqueta a nivel de lámina (“este trombo era cardioembólico”), pero no a nivel de cada tile. El MIL permite decirle al modelo: “esta bolsa de parches pertenece a la clase X” sin etiquetar uno por uno. Esto se ha usado en patología clínica para diagnóstico con láminas completas.

3. **Vision Transformers (ViT) y variantes para patología digital**

Los Vision Transformers (ViT) son una familia de modelos de Deep Learning basados en la arquitectura Transformer, originalmente desarrollada para procesamiento de lenguaje natural (NLP). En lugar de usar convoluciones (CNN), los ViT dividen una imagen en pequeños parches por ejemplo, de 16×16 píxeles, los linealizan y los tratan como una secuencia de tokens, de forma similar a cómo un Transformer procesa palabras en una oración.

4. **Modelos de segmentación tipo U-Net cuando se quiere primero extraer regiones relevantes**

U-Net es una red neuronal convolucional (CNN) diseñada específicamente para segmentación de imágenes biomédicas. Fue propuesta por Ronneberger et al. (2015) en la conferencia MICCAI para segmentar células en microscopía. Su nombre proviene de la forma en “U” de su arquitectura, compuesta por dos caminos principales:

- Encoder (contracción) → reduce progresivamente la resolución de la imagen y aprende características complejas.
- Decoder (expansión) → reconstruye la imagen segmentada pixel por pixel, usando skip connections para recuperar detalles espaciales finos.

Modelos Desarrollados

Evaluación de Modelos

1. **CNN**

Durante el desarrollo del modelo CNN se llevaron a cabo múltiples ajustes de hiperparámetros y estrategias de optimización con el objetivo de mejorar la estabilidad del entrenamiento y el rendimiento de la red.




- **Reducción y recorte de imágenes (Crop dinámico):** Dado que las imágenes originales del conjunto de datos poseen una resolución extremadamente alta, se implementó un recorte (crop) controlado para extraer secciones representativas de cada escaneo.
- **Se probaron tamaños de recorte de 512×512 , 1024×1024 y 2048×2048 píxeles.**


Finalmente se adoptó un tamaño de 224×224 , correspondiente a la entrada esperada por los modelos EfficientNet y ResNet, lo que permitió mantener la eficiencia computacional sin perder información relevante.

Además, se incorporó la opción de random crop para aumentar la diversidad de patrones visuales durante el entrenamiento.

- **Balanceo de clases mediante pesos:** Se detectó un desbalance entre las etiquetas de las imágenes. Para contrarrestar este efecto y evitar que el modelo favorece las clases mayoritarias, se calcularon pesos inversamente proporcionales a la frecuencia de cada clase y se integraron en la función de pérdida (Cross Entropy Loss).
Esto permitió penalizar de forma más fuerte los errores en clases minoritarias, mejorando la métrica F1-score general.
- **Optimizador y tasa de aprendizaje:** Se utilizó el optimizador Adam con una tasa de aprendizaje inicial de $1e-4$, y posteriormente se redujo a $3e-5$ para lograr una convergencia más estable en las últimas etapas del entrenamiento. Adam fue elegido por su capacidad de ajustar dinámicamente la magnitud de las actualizaciones en función del gradiente acumulado.
- **Aumentos de datos (Data Augmentation):** Con el fin de mejorar la generalización del modelo frente a variaciones en color y orientación, se aplicaron transformaciones de:
 - RandomHorizontalFlip()
 - RandomVerticalFlip()
 - ColorJitter(brightness=0.2, contrast=0.2, saturation=0.2)
- **RandomRotation(15)**
Estas técnicas aumentaron la robustez del modelo ante cambios de iluminación, rotación o contraste en las láminas histológicas.
- **Número de épocas y tamaño de lote:**
Dado el alto costo computacional, se empleó un número reducido de épocas (10) y un tamaño de lote pequeño (batch size = 2) para evitar sobrecargas de memoria. Aunque esto limita el aprendizaje profundo de las representaciones, permitió validar la estabilidad y direccionalidad del entrenamiento.

- **Resultados**





2. MIL

Para abordar el problema de clasificación planteado, se propone la implementación de un modelo basado en aprendizaje por instancias múltiples (Multiple Instance Learning, MIL). Este enfoque resulta especialmente adecuado, dado que cada paciente cuenta con múltiples imágenes de escaneo (scans) que comparten un mismo contexto clínico y una etiqueta global. El modelo, por tanto, debe ser capaz de integrar información proveniente de varias instancias (imágenes) asociadas a un mismo paciente para emitir una predicción conjunta.

- *Metodología:*

La implementación de este modelo se realizará en base a los siguientes pasos

- Reducir el tamaño de las imágenes
- Agrupar datos en Bolsas
- Implementar CNN clasificatoria
- Entrenar con partición de entrenamiento
- Evaluar rendimiento

- *Agrupación de Instancias*

Las instancias, es decir, las imágenes y contexto clínico de un paciente, fueron agrupados con una clase de Python customizada. Con la implementación de funciones nativas, podemos integrarlo con un DataLoader y así enlazarlo directamente al entrenamiento del modelo CNN.

- *Red Neuronal*

El modelo propuesto se construye sobre una red neuronal convolucional (CNN) con una arquitectura tipo Encoder–Decoder, incorporando mecanismos de atención inspirados en ResNet. La elección de ResNet18 como base del encoder permite aprovechar los pesos preentrenados en ImageNet, lo que reduce significativamente el costo computacional y el tiempo de entrenamiento, al reutilizar representaciones semánticas ya optimizadas para tareas de visión por computadora.

A nivel estructural, los módulos de atención y las capas adicionales fueron diseñados específicamente para procesar grupos de imágenes pertenecientes a un mismo paciente, permitiendo que el modelo aprenda a identificar patrones comunes y relaciones espaciales entre las distintas instancias del conjunto. Este mecanismo busca reforzar la consistencia de las predicciones a nivel de paciente, y no únicamente a nivel de imagen individual.


En cuanto a la configuración del entrenamiento, se utiliza la función de pérdida Cross Entropy Loss, adecuada para tareas de clasificación multiclase. Además, se emplea el optimizador Adam, que proporciona una convergencia estable y eficiente gracias a su adaptación dinámica de las tasas de aprendizaje.

En conjunto, esta arquitectura pretende capturar de manera efectiva las características relevantes de las imágenes médicas y consolidar la información contextual entre los distintos scans de un mismo paciente, optimizando así el desempeño del modelo en un entorno clínico realista.

• *Entrenamiento*

Debido a que esta etapa únicamente comprende la evaluación inicial de posibles modelos, se considera un número reducido de épocas con únicamente 5 repeticiones. Ya que el conjunto de data es bastante grande, y las imágenes están descomprimidas, el uso de recursos de cómputo y tiempo de ejecución se elevan en esta etapa, por lo que simplificar el proceso lo más posible es imperativo

• *Resultados*



- *Discusión*

El modelo presenta indicios claros de sobreajuste, evidentes en el comportamiento de las métricas de entrenamiento, validación y prueba. En primer lugar, la curva de aprendizaje muestra una disminución sostenida del *training loss* (de aproximadamente 0.85 a 0.53), mientras que el *validation loss* se mantiene elevado hasta la segunda época, momento en el que colapsa bruscamente al mismo nivel que el de entrenamiento. Este comportamiento sugiere que el modelo no logró generalizar correctamente, sino que terminó memorizando los datos de validación.

De manera consistente, la precisión refleja un patrón inestable: el *training accuracy* alcanza cerca del 83%, pero el *validation accuracy* fluctúa entre 38% y 48% en las primeras épocas, estabilizándose recién hacia un 74%. Esta inestabilidad inicial refuerza la hipótesis de un entrenamiento poco robusto.

La matriz de confusión correspondiente a la última época muestra además un marcado sesgo hacia la clase CE, con 9 de 10 predicciones pertenecientes a dicha clase. Aunque la precisión global (90%) parece elevada, este valor es engañoso debido al desbalance de clases. La clase LAA presenta un *recall* de 75%, con un falso negativo que podría tener implicaciones clínicas importantes, evidenciando el riesgo de depender de un modelo con comportamiento sesgado.

En conjunto, estos resultados indican que el modelo presenta problemas de generalización y de distribución de clases. Se recomienda balancear el conjunto de datos o aplicar técnicas de ponderación de clases, además de incorporar métodos de regularización (como *dropout* o *weight decay*) y un conjunto de prueba de mayor tamaño ($n > 100$) para obtener métricas más confiables. Finalmente, la aplicación de validación cruzada y el uso de *early stopping* antes del colapso observado en la época 2–3 podrían contribuir a mejorar la estabilidad y la capacidad de generalización del modelo.

Resultados y Discusion

En la comparación, el CNN presenta un aprendizaje estable: la pérdida descende de forma sostenida y el *accuracy* se mantiene ~72–74% tanto en entrenamiento como en validación, con brecha mínima entre curvas. No obstante, el F1 se estabiliza en ~0.42–0.45, lo que evidencia dificultades para recuperar la clase minoritaria pese al uso de *class weights* y *augmentations*; el $\text{batch}=2$ y las estadísticas ruidosas de *BatchNorm* probablemente limitan la discriminación fina por clase.

El MIL, por su parte, alcanza picos de *train accuracy* más altos (~83%) y valida cerca de ~74%, pero muestra inestabilidad: el *validation loss* colapsa alrededor de las épocas 2–3 y la *val accuracy* oscila antes de estabilizarse. La matriz de confusión (6/0/1/3) revela sesgo hacia CE y un *recall* incompleto en LAA, típico de escenarios con etiquetas a nivel de bolsa y ruido de instancia (no todos los parches son informativos). Esto sugiere que el MIL ya está captando contexto por paciente, pero requiere mejor regularización y control del sobreajuste.

En síntesis, el CNN ofrece generalización consistente pero menor sensibilidad por clase, mientras que el MIL aporta capacidad de agregación a nivel paciente con riesgo de sobreajuste y sesgo de clase. Para converger, se recomienda: *split* estricto por paciente, sampler balanceado o Focal Loss, scheduler con *early stopping*, calibración de probabilidades

y un MIL con *attention pooling* usando el CNN como extractor de *features*; con ello debería incrementarse el F1 de la clase minoritaria sin perder la estabilidad observada en el CNN.

Conclusión

Se concluye que ambos enfoques son viables y complementarios: el CNN es un *baseline* confiable para extraer representaciones a nivel de parche, y el MIL es prometedor para decisión clínica a nivel de paciente, siempre que se aborde el balanceo de clases, se incremente el tamaño del set de prueba, y se apliquen regularización y early stopping. Para la siguiente fase, se recomienda unificar: usar el CNN como extractor de *features* y un MIL con *attention pooling*, incorporar samplers/focal loss, scheduler y calibración de probabilidades, y reportar métricas por clase y por paciente; el objetivo es elevar el F1 de la clase minoritaria manteniendo la estabilidad observada en el CNN.


Fase 3 – Aplicación / Dashboard y resultados finales

Introducción

En la tercera fase del proyecto, el objetivo principal fue integrar los modelos desarrollados en las etapas anteriores dentro de una herramienta interactiva, de forma que el análisis no se quedara únicamente en notebooks, sino que se tradujera en una aplicación funcional para explorar la etiología de trombos.

Se construyó un dashboard denominado “STRIP AI – Dashboard de Clasificación de Etiología”, el cual permite configurar el experimento, seleccionar el modelo a utilizar (CNN o MIL), cargar nuevas láminas y visualizar tanto las curvas de entrenamiento como las predicciones generadas por los modelos.

Diseño y estructura de la aplicación



STRIP AI – Dashboard de Clasificación de Etiología

Demostración interactiva con dos modelos: CNN (ResNet/EfficientNet) y MIL (Multiple Instance Learning).

Configuración del experimento

Modelo a usar

CNN (imagen única) ▼

Tamaño de entrada (px)

224

Tamaño de crop sobre thumbnail

2048

Sube una lámina



Drag and drop file here

Limit 500MB per file • TIF, TIFF, JPG, JPEG, PNG

Browse files





00c058_0_tissue2048.jpg 2.3MB



Curvas de entrenamiento

CNN MIL


MIL - Pérdida




Thumbnail del slide (nivel bajo)

Predicción con MIL

Predicción MIL (bolsa de 6 tiles): CE





La aplicación se organizó alrededor de tres bloques principales:

Configuración del experimento

En esta sección el usuario puede:

Seleccionar el modelo a utilizar:

- MIL (bolsa de tiles), que agrupa múltiples parches de una misma lámina/paciente.
- CNN (imagen única), que evalúa un recorte individual de la WSI.
- Ajustar hiperparámetros visuales del experimento, como el tamaño de entrada (224 px) y el tamaño del crop sobre el thumbnail, que controla la porción de la lámina que se analizará.
- Definir el número de tiles en el caso del enfoque MIL.

Carga de láminas

La aplicación incluye un componente de carga de archivos donde el usuario puede arrastrar y soltar una WSI (en formatos TIFF, JPG, PNG, entre otros). La lámina se procesa con el mismo pipeline de preprocesamiento descrito en las fases anteriores: recorte, normalización y, en el caso de MIL, generación de una bolsa de tiles por paciente.

Curvas de entrenamiento y métricas


En el panel derecho se muestran las curvas de pérdida de cada modelo (CNN y MIL) durante el entrenamiento, lo que permite evaluar visualmente la estabilidad del aprendizaje, detectar signos de sobreajuste y comparar el comportamiento entre ambos enfoques.

Visualizaciones y funcionalidades interactivas del dashboard

El dashboard incorpora diferentes visualizaciones que conectan directamente con los resultados de la Fase 2 y los hacen accesibles para el usuario:

Curvas de entrenamiento por modelo

- Se muestran gráficos de la pérdida de entrenamiento y validación tanto para la CNN como para el modelo MIL. En ellos se observa que:
- La CNN (ResNet18) presenta una pérdida relativamente estable, con una brecha pequeña entre `train_loss` y `val_loss`.
- El modelo MIL muestra una reducción rápida de la pérdida pero con mayor variabilidad en la validación, lo que coincide con los indicios de sobreajuste discutidos anteriormente.



Resumen numérico de desempeño (F1-score)

Debajo de las curvas se incluyen los valores de F1 en entrenamiento y validación para ambos modelos:


MIL: F1 (train) ≈ 0.73 , F1 (val) ≈ 0.64 .

ResNet18: F1 (train) ≈ 0.512 , F1 (val) ≈ 0.483 .

Estos resultados refuerzan la idea de que el enfoque MIL captura mejor la información a nivel de paciente, aunque con mayor riesgo de sobreajuste.

Matriz de confusión para ResNet18

La aplicación también muestra una matriz de confusión para la CNN, donde se observa un sesgo hacia la clase CE, con varias instancias LAA clasificadas erróneamente. Esto confirma la importancia de evaluar el modelo por clase y no únicamente con métricas globales.



Predicciones por paciente con MIL

Cuando se selecciona el modelo MIL y se carga una lámina, el dashboard muestra:

- Un thumbnail de baja resolución de la WSI.
- Un mensaje con la predicción global de la bolsa de tiles (por ejemplo, “Predicción MIL (bolsa de 6 tiles): CE”).
- Un gráfico de barras con las probabilidades asignadas a CE y LAA.
- En el ejemplo mostrado, el modelo MIL asigna una probabilidad cercana a 1.0 a la clase CE, lo que indica una decisión muy confiada.

Predicciones por paciente con CNN

De forma análoga, al seleccionar la CNN:

- Se muestra un crop central de 512 px de la lámina evaluada.
- Se presenta la etiqueta predicha (CE o LAA) y el gráfico de barras con las probabilidades para cada clase.
- En el ejemplo ilustrado, la CNN predice LAA con una ligera ventaja sobre CE, reflejando un caso donde ambos modelos no necesariamente coinciden, lo cual es útil para análisis comparativos.

Resultados finales de la aplicación

La aplicación permite integrar de forma coherente los hallazgos de las fases anteriores:

- Confirma que el modelo MIL ofrece un mejor F1 global, especialmente cuando se considera información a nivel de paciente.
- Muestra que la CNN es más estable en sus curvas de entrenamiento, pero sigue teniendo dificultades para capturar correctamente la clase LAA en un escenario desbalanceado.
- Facilita la detección visual de sobreajuste y sesgo de clase, a través de las curvas de pérdida, métricas y matrices de confusión.

En términos de usabilidad, la interfaz permite que un usuario pueda:

- Configurar rápidamente el experimento.
- Cargar nuevas láminas sin modificar el código.
- Explorar de manera visual y comparativa el comportamiento de los dos modelos implementados.

Conclusión

La Fase 3 logró transformar el trabajo de modelado en una herramienta funcional, cumpliendo con el objetivo de desarrollar una aplicación que integre los modelos entrenados y ofrezca visualizaciones interactivas de sus resultados.

El dashboard STRIP AI demuestra que es posible:

- Procesar láminas histopatológicas reales mediante un pipeline reproducible.
- Obtener predicciones CE vs LAA tanto a nivel de parche (CNN) como a nivel de paciente (MIL).
- Comunicar el rendimiento de los modelos de forma clara para un usuario no experto en machine learning.

Esta fase cierra el ciclo del proyecto, pasando de la exploración de datos y el diseño de modelos a una propuesta de herramienta que podría servir como base para futuros sistemas de apoyo a la decisión clínica.

Discusión:

Desafíos encontrados

Uno de los principales desafíos fue el tamaño y la naturaleza de las WSI. Las imágenes originales tienen una resolución muy alta, lo que hace imposible procesarlas directamente en un solo paso por limitaciones de memoria y tiempo de cómputo. Esto obligó a diseñar un pipeline de recorte en tiles, filtrado de regiones no informativas y reducción de tamaño antes de alimentar los modelos.

Otro reto importante fue el desbalance de clases entre CE y LAA. La mayoría de las muestras pertenecen a la clase cardioembólica, lo que tiende a sesgar a los modelos hacia esa etiqueta si se entrena de forma ingenua. Este desbalance se reflejó en las matrices de confusión y en la dificultad para obtener buenos valores de F1 en la clase minoritaria.

Finalmente, el proyecto estuvo condicionado por restricciones computacionales y de tiempo. Debido al tamaño del dataset y a la complejidad de los modelos, fue necesario limitar el número de épocas y el tamaño de lote, especialmente en el enfoque MIL, donde cada bolsa agrupa múltiples tiles por paciente. Esto dificulta la exploración exhaustiva de arquitecturas e hiperparámetros.

Decisiones tomadas

Frente a estos retos se tomaron varias decisiones de diseño:

Se eligió ResNet18 como backbone principal, aprovechando sus pesos preentrenados en ImageNet para reducir tiempos de entrenamiento, pero manteniendo una arquitectura relativamente ligera.

Se implementó un enfoque de Multiple Instance Learning (MIL) para trabajar a nivel de paciente, agrupando tiles en bolsas y utilizando un mecanismo de agregación con atención ligera. Esto permitió aprovechar mejor la estructura del problema, donde la etiqueta es global para el paciente.

Para lidiar con el desbalance, se utilizaron pesos de clase en la función de pérdida y técnicas de data augmentation (rotaciones, flips, ajustes de brillo y contraste), con el fin de mejorar la capacidad de generalización.

Se decidió mantener un pipeline de preprocesamiento unificado para la CNN y el modelo MIL, de modo que las mismas transformaciones se utilizaran tanto en entrenamiento como en la aplicación final. Esto reduce inconsistencias entre fases y facilita la integración en el dashboard.

En cuanto a la aplicación, se optó por un dashboard interactivo que expone las curvas de entrenamiento, las métricas globales y las predicciones por paciente. La decisión fue priorizar claridad y facilidad de uso sobre funcionalidades complejas, para que cualquier usuario pueda explorar el comportamiento de los modelos sin entrar al código.

Lecciones aprendidas

Entre las lecciones más relevantes se encuentran:

La importancia de diseñar el pipeline desde el inicio pensando en la fase de despliegue. Reutilizar el mismo preprocesamiento en notebooks y en la aplicación evita errores sutiles y resultados inconsistentes.

La necesidad de evaluar siempre por clase, más allá de la accuracy global. En un contexto clínico, equivocarse sistemáticamente en la clase minoritaria puede tener consecuencias graves, aunque la métrica global parezca aceptable.

El valor de las visualizaciones interactivas para comunicar resultados. Ver las curvas de pérdida, matrices de confusión y probabilidades por paciente dentro del dashboard hace que el comportamiento del modelo sea mucho más tangible que solo leer números.

Finalmente, se confirma que modelos más complejos (como MIL) pueden ofrecer mejor desempeño, pero también son más sensibles a temas de regularización, desbalance y sobreajuste. La experimentación cuidadosa y el monitoreo gráfico constante son claves para evitar conclusiones falsas.

Conclusiones y trabajo futuro

El proyecto logró implementar una solución integral para la clasificación de etiología de trombos (CE vs LAA) basada en imágenes histopatológicas. Se construyó un pipeline completo que va desde el análisis exploratorio, pasando por el entrenamiento de modelos, hasta la implementación de un dashboard interactivo. Esto permitió demostrar, de manera práctica, cómo los conceptos del curso de Data Science pueden aplicarse a un problema biomédico real.

En términos de resultados, la **CNN basada en ResNet18** ofreció un comportamiento estable en entrenamiento y validación, constituyéndose como un **baseline confiable** a nivel de parche, aunque con limitaciones para capturar correctamente la clase minoritaria. Por otro lado, el **modelo MIL** demostró ser más prometedor a nivel de paciente, alcanzando mejores valores de F1 global, pero también evidenciando **riesgo de sobreajuste y sesgo hacia CE**, especialmente cuando no se controla adecuadamente la regularización y el balanceo de clases.

La aplicación **STRIP AI – Dashboard de Clasificación de Etiología** consolidó todo este trabajo en una herramienta funcional. El usuario puede configurar experimentos, cargar nuevas láminas y visualizar predicciones y métricas de manera gráfica, lo cual acerca el modelo a un posible escenario de apoyo a la decisión clínica.

Como trabajo futuro, se proponen varias líneas de mejora:

- Explorar **técnicas de pérdida alternativas**, como Focal Loss o Balanced Cross Entropy, para mejorar el desempeño en la clase LAA.
- Incorporar **métodos de regularización más fuertes** (dropout, weight decay) y estrategias de **early stopping** y *learning rate schedulers* más sofisticados.
- Aumentar el tamaño del conjunto de prueba y utilizar **validación cruzada estratificada por paciente**, para obtener métricas más robustas.
- Usar el backbone CNN únicamente como **extractor de características** y construir encima modelos MIL con **attention pooling** más avanzados.
- Integrar **métodos de explicabilidad** (por ejemplo, Grad-CAM o visualizaciones de atención por tile) que permitan identificar regiones concretas del trombo que influyen en la decisión del modelo.

Estas mejoras podrían acercar aún más el sistema a un escenario clínico real, donde la combinación de rendimiento, interpretabilidad y estabilidad es fundamental.

Referencias y anexos:

Referencias clave

- He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep Residual Learning for Image Recognition*. CVPR.
- Ilse, M., Tomczak, J., & Welling, M. (2018). *Attention-based Deep Multiple Instance Learning*. ICML.
- Ronneberger, O., Fischer, P., & Brox, T. (2015). *U-Net: Convolutional Networks for Biomedical Image Segmentation*. MICCAI.
- Kingma, D. P., & Ba, J. (2015). *Adam: A Method for Stochastic Optimization*. ICLR.

Anexos

- Repositorio de código del proyecto
URL: <https://github.com/Andyfer004/P2-DS>
- Document de google docs:

URL: <https://docs.google.com/document/d/1Vc2qUyLNyJMzcXxc1thJKs6VxDsNFZViHNfB6j3GUAo/edit?usp=sharing>
- Presentación de resultados finales (Proyecto 2 – Fase 3)

URL: https://www.canva.com/design/DAG4U45Wf0s/RFBHgqhV2gfwpmWse5D-3w/edit?utm_content=DAG4U45Wf0s&utm_campaign=designshare&utm_medium=link2&utm_source=sharebutton