

PROYECTO 2 – ANÁLISIS EXPLORATORIO

ORIGEN DEL TROMBO (CE VS LAA)

GRUPO 7

INTEGRANTES



JOSÉ MARCHENA

INGENIERO DE DATOS

Analizó color/texture (RGB-HED), definió métricas de cobertura y enfoque, e hizo visualizaciones.



DAVIS ROLDAN

INGENIERO DE DATOS

Preparó dataset, tileado y filtros de calidad; normalizó tinción y automatizó extracción de features.



ANDY FUENTES

LIDER TÉCNICO

Estructuró el repo y pipelines, integró notebooks reutilizables, exploró UMAP/t-SNE y revisó PRs.



GABRIEL PAZ

COORDINACIÓN & PRESENTACIÓN

Planificó el trabajo, consolidó hallazgos, redactó reporte/slides y definió implicaciones para modelado.


PLANTEAMIENTO DE LA PROBLEMÁTICA



CLASIFICACIÓN BINARIA DEL ORIGEN DEL TROMBO

- Cardioembólico (CE)
- Suele tratarse con anticoagulantes.
- Ateroescclerosis de arteria grande (LAA)
- Suele sugerir antiagregantes.

Alta incertidumbre del origen $\Rightarrow$ apoyo con modelos de aprendizaje profundo.



OBJETIVO GENERAL Y ESPECIFICOS



OBJETIVO GENERAL:


Realizar EDA para identificar patrones relevantes (color, textura, tejido).

OBJETIVOS ESPECÍFICOS:

- Describir estructura y distribución del dataset (clases, metadatos).
- Preprocesar: filtrar tiles no informativos y normalizar tinción.
- Explorar métricas de color, textura y cobertura de tejido.
- Visualizar: histogramas, boxplots, UMAP/t-SNE.

DATASET Y METADATOS



Dataset STRIP AI: WSI H&E con etiquetas CE/LAA y variación entre centros.
El EDA se centra en clases, calidad de imagen y patrones de color que influyen en la separabilidad.



CALIDAD: COBERTURA DEL TEJIDO

COBERTURA DE TEJIDO EN TILES


- **Métrica:** % de píxeles “tejido” por tile.
- **Hallazgo:** Mediana $\approx$ [X%], con colas en [bajo/alto].
- **Decisión:** Filtrar tiles con cobertura $<$ [umbral%]




CALIDAD: DESENFUQUE/NITIDEZ

NITIDEZ (VARIANZA DEL LAPLACIANO)


- **Métrica:** Varianza del Laplaciano por tile.
- **Hallazgo:** Mayor densidad en [rango]; outliers borrosos identificados.
- **Decisión:** Excluir tiles con $VL < [\text{umbral}]$.




COLOR: RGB



R




G




B

Tendencias por canal (R, G, B) sugieren diferencias en eosina/hematoxilina.

TINCIÓN H&E




H



E

Picos en componentes H (núcleos) y E (citoplasma) revelan consistencia/variación.

RESULTADOS PRINCIPALES



HALLAZGOS CLAVE DEL EDA

- **Desbalance de clases:** $CE/LAA = [X/Y]\%$ → usar class weights o re-muestreo.
- **Calidad:** Filtros por tejido/nitidez mejoran señal y reducen ruido.
- **Color/H&E:** Variabilidad inter-centro mitigable con normalización.
- **Relaciones:** Features de color/tejido aportan señal; separabilidad preliminar en UMAP/t-SNE.

CORRELACIÓN ENTRE METRICAS


Se puede observar una correlación presente entre los canales de color, especialmente entre verde y azul, lo cual se puede correlacionar con la presencia de los tintes mencionados anteriormente, así como con la intensidad de un pixel dado. También, la cobertura de tejido se ve relacionada con la nitidez de una imagen, lo cual nos indica que el contenido de tejido de una imagen tiende a tener alto enfoque una vez se presenta.

Tiles con mayor blur_var:

	image_id	label	blur_var	z	x	y	tile
16	02ebd5_0	NA	7417.539625	3.895829	155	160	128
39	0412ab_0	NA	6450.141297	3.090653	710	433	128
25	0412ab_0	NA	5288.784599	2.124043	532	477	128
47	0412ab_0	NA	4935.782998	1.830236	1586	1790	128
13	02ebd5_0	NA	4771.958963	1.693884	183	392	128
19	02ebd5_0	NA	4393.051270	1.378515	1387	1051	128
26	0412ab_0	NA	4294.555516	1.296536	540	263	128
41	0412ab_0	NA	3915.174417	0.980773	503	701	128

Tiles con menor tissue_ratio:

	image_id	label	tissue_ratio	x	y	tile
32	0412ab_0	NA	0.264160	1119	2430	128
46	0412ab_0	NA	0.320374	380	2284	128
62	08b8ef_0	NA	0.329102	860	453	128
51	08b8ef_0	NA	0.351990	1094	807	128
44	0412ab_0	NA	0.383423	739	1888	128
33	0412ab_0	NA	0.394226	1541	1792	128
41	0412ab_0	NA	0.430237	503	701	128
48	08b8ef_0	NA	0.432678	565	2644	128



CONCLUSIONES



¿QUÉ HARÍAMOS AL MODELAR?

Aplicar class weights / focal loss y estrategias de balanceo.

Entrenar con tiles curados (umbrales de tejido y VL validados).

Normalización de tinción en el pipeline.

Probar CNN/ViT con validación estratificada por centro para evitar fuga de información.

**MUCHAS
GRACIAS!**

