

UNIVERSIDAD DEL VALLE DE GUATEMALA
Facultad de Ingeniería



Proyecto 2
Fase 2: Resultados Iniciales

Andy Fuentes, 22944
Gabriel Alberto Paz, 221087
Davis Alejandro Roldan, 22672
José Rodrigo Marchena, 22398

Luis Roberto Furlan
Data Science

Repositorio

<https://github.com/Andyfer004/P2-DS>

Documento:

[Proyecto 2 Fase 2 - Data Science.docx](#)

Introducción

Problema STRIP: etiología de stroke a partir de trombos

En un stroke isquémico el coágulo puede venir de distintos orígenes ya sea cardioembólico, aterosclerótico de gran vaso, o causas poco comunes. Saber el origen ayuda a decidir la terapia secundaria como anticoagulación y antiagregación. Como ahora los coágulos se extraen con trombectomía mecánica, hay material para analizarlo con IA. El reto principal son las preparaciones histológicas son grandes, heterogéneas y no siempre están anotadas a nivel de parche.

Objetivos

General. Evaluar la viabilidad de un enfoque **MIL** con backbone **CNN (ResNet18)** para clasificar la etiología de trombos (CE vs LAA) en el reto STRIP usando bolsas de imágenes por paciente.

Específicos.

1. Preparar el pipeline: reducción de tamaño, agrupación por paciente (bolsas) y DataLoader compatible con MIL.
2. Implementar una CNN encoder-decoder con atención ligera y **CrossEntropy + Adam**.
3. Entrenar un prototipo en **5 épocas** para obtener curvas iniciales de pérdida y precisión.
4. Evaluar por paciente y por clase (matriz de confusión) e identificar riesgos de sobreajuste y sesgo de clase.
5. Proponer ajustes de regularización, balanceo y validación para la siguiente fase.

Investigación de Algoritmos

Algoritmos/modelos en problemas similares

1. **Redes Neuronales Convolucionales (CNN) para histopatología**

Las CNN tipo ResNet, DenseNet y EfficientNet se han usado mucho para clasificar tejidos en patología digital (cáncer, trombos, placas). Funcionan bien porque capturan texturas y patrones de color de fibrina, hematíes y leucocitos, que son justo las características que en stroke se asocian a distintos orígenes del trombo. Para nuestro reto STRIP se debe entrenar una CNN sobre parches del trombo para predecir el tipo de etiología.

2. Multiple Instance Learning (MIL) / weakly supervised learning para whole-slide images

En patología de coágulos pasa lo mismo que en otras WSI: tienes la etiqueta a nivel de lámina (“este trombo era cardioembólico”), pero no a nivel de cada tile. El MIL permite decirle al modelo: “esta bolsa de parches pertenece a la clase X” sin etiquetar uno por uno. Esto se ha usado en patología clínica para diagnóstico con láminas completas.

3. Vision Transformers (ViT) y variantes para patología digital

Los Vision Transformers (ViT) son una familia de modelos de Deep Learning basados en la arquitectura Transformer, originalmente desarrollada para procesamiento de lenguaje natural (NLP). En lugar de usar convoluciones (CNN), los ViT dividen una imagen en pequeños parches por ejemplo, de 16×16 píxeles, los linealizan y los tratan como una secuencia de tokens, de forma similar a cómo un Transformer procesa palabras en una oración.

4. Modelos de segmentación tipo U-Net cuando se quiere primero extraer regiones relevantes

U-Net es una red neuronal convolucional (CNN) diseñada específicamente para segmentación de imágenes biomédicas. Fue propuesta por Ronneberger et al. (2015) en la conferencia MICCAI para segmentar células en microscopía. Su nombre proviene de la forma en “U” de su arquitectura, compuesta por dos caminos principales:

- Encoder (contracción) → reduce progresivamente la resolución de la imagen y aprende características complejas.
- Decoder (expansión) → reconstruye la imagen segmentada pixel por pixel, usando skip connections para recuperar detalles espaciales finos.

Modelos Desarrollados

Evaluación de Modelos

1. CNN

Durante el desarrollo del modelo CNN se llevaron a cabo múltiples ajustes de hiperparámetros y estrategias de optimización con el objetivo de mejorar la estabilidad del entrenamiento y el rendimiento de la red.

- **Reducción y recorte de imágenes (Crop dinámico):** Dado que las imágenes originales del conjunto de datos poseen una resolución extremadamente alta, se implementó un recorte (crop) controlado para extraer secciones representativas de cada escaneo.
- **Se probaron tamaños de recorte de 512×512 , 1024×1024 y 2048×2048 píxeles.**

Finalmente se adoptó un tamaño de 224×224 , correspondiente a la entrada esperada por los modelos EfficientNet y ResNet, lo que permitió mantener la eficiencia computacional sin perder información relevante.

Además, se incorporó la opción de random crop para aumentar la diversidad de patrones visuales durante el entrenamiento.

- **Balanceo de clases mediante pesos:** Se detectó un desbalance entre las etiquetas de las imágenes. Para contrarrestar este efecto y evitar que el modelo favorece las clases mayoritarias, se calcularon pesos inversamente proporcionales a la frecuencia de cada clase y se integraron en la función de pérdida (Cross Entropy Loss).

Esto permitió penalizar de forma más fuerte los errores en clases minoritarias, mejorando la métrica F1-score general.

- **Optimizador y tasa de aprendizaje:** Se utilizó el optimizador Adam con una tasa de aprendizaje inicial de $1e-4$, y posteriormente se redujo a $3e-5$ para lograr una convergencia más estable en las últimas etapas del entrenamiento. Adam fue elegido por su capacidad de ajustar dinámicamente la magnitud de las actualizaciones en función del gradiente acumulado.
- **Aumentos de datos (Data Augmentation):** Con el fin de mejorar la generalización del modelo frente a variaciones en color y orientación, se aplicaron transformaciones de:

- RandomHorizontalFlip()
- RandomVerticalFlip()
- ColorJitter(brightness=0.2, contrast=0.2, saturation=0.2)




- **RandomRotation(15)**


Estas técnicas aumentaron la robustez del modelo ante cambios de iluminación, rotación o contraste en las láminas histológicas.

- **Número de épocas y tamaño de lote:**

Dado el alto costo computacional, se empleó un número reducido de épocas (10) y un tamaño de lote pequeño (batch size = 2) para evitar sobrecargas de memoria. Aunque esto limita el aprendizaje profundo de las representaciones, permitió validar la estabilidad y direccionalidad del entrenamiento.

- **Resultados**





2. MIL

Para abordar el problema de clasificación planteado, se propone la implementación de un modelo basado en aprendizaje por instancias múltiples (Multiple Instance Learning, MIL). Este enfoque resulta especialmente adecuado, dado que cada paciente cuenta con múltiples imágenes de escaneo (scans) que comparten un mismo contexto clínico y una etiqueta global. El modelo, por tanto, debe ser capaz de integrar información proveniente de varias instancias (imágenes) asociadas a un mismo paciente para emitir una predicción conjunta.

- *Metodología:*

La implementación de este modelo se realizará en base a los siguientes pasos

- a. Reducir el tamaño de las imágenes
- b. Agrupar datos en Bolsas
- c. Implementar CNN clasificatoria
- d. Entrenar con partición de entrenamiento
- e. Evaluar rendimiento

- *Agrupación de Instancias*

Las instancias, es decir, las imágenes y contexto clínico de un paciente, fueron agrupados con una clase de Python customizada. Con la implementación de funciones nativas,

podemos integrarlo con un DataLoader y así enlazarlo directamente al entrenamiento del modelo CNN.

- *Red Neuronal*

El modelo propuesto se construye sobre una red neuronal convolucional (CNN) con una arquitectura tipo Encoder–Decoder, incorporando mecanismos de atención inspirados en ResNet. La elección de ResNet18 como base del encoder permite aprovechar los pesos preentrenados en ImageNet, lo que reduce significativamente el costo computacional y el tiempo de entrenamiento, al reutilizar representaciones semánticas ya optimizadas para tareas de visión por computadora.

A nivel estructural, los módulos de atención y las capas adicionales fueron diseñados específicamente para procesar grupos de imágenes pertenecientes a un mismo paciente, permitiendo que el modelo aprenda a identificar patrones comunes y relaciones espaciales entre las distintas instancias del conjunto. Este mecanismo busca reforzar la consistencia de las predicciones a nivel de paciente, y no únicamente a nivel de imagen individual.


En cuanto a la configuración del entrenamiento, se utiliza la función de pérdida Cross Entropy Loss, adecuada para tareas de clasificación multiclase. Además, se emplea el optimizador Adam, que proporciona una convergencia estable y eficiente gracias a su adaptación dinámica de las tasas de aprendizaje.

En conjunto, esta arquitectura pretende capturar de manera efectiva las características relevantes de las imágenes médicas y consolidar la información contextual entre los distintos scans de un mismo paciente, optimizando así el desempeño del modelo en un entorno clínico realista.

- *Entrenamiento*

Debido a que esta etapa únicamente comprende la evaluación inicial de posibles modelos, se considera un número reducido de épocas con únicamente 5 repeticiones. Ya que el conjunto de data es bastante grande, y las imágenes están descomprimidas, el uso de recursos de cómputo y tiempo de ejecución se elevan en esta etapa, por lo que simplificar el proceso lo más posible es imperativo

- *Resultados*



- *Discusión*

El modelo presenta indicios claros de sobreajuste, evidentes en el comportamiento de las métricas de entrenamiento, validación y prueba. En primer lugar, la curva de aprendizaje muestra una disminución sostenida del *training loss* (de aproximadamente 0.85 a 0.53), mientras que el *validation loss* se mantiene elevado hasta la segunda época, momento en el que colapsa bruscamente al mismo nivel que el de entrenamiento. Este comportamiento sugiere que el modelo no logró generalizar correctamente, sino que terminó memorizando los datos de validación.

De manera consistente, la precisión refleja un patrón inestable: el *training accuracy* alcanza cerca del 83%, pero el *validation accuracy* fluctúa entre 38% y 48% en las primeras épocas, estabilizándose recién hacia un 74%. Esta inestabilidad inicial refuerza la hipótesis de un entrenamiento poco robusto.

La matriz de confusión correspondiente a la última época muestra además un marcado sesgo hacia la clase CE, con 9 de 10 predicciones pertenecientes a dicha clase. Aunque la precisión global (90%) parece elevada, este valor es engañoso debido al desbalance de clases. La clase LAA presenta un *recall* de 75%, con un falso negativo que podría tener implicaciones clínicas importantes, evidenciando el riesgo de depender de un modelo con comportamiento sesgado.

En conjunto, estos resultados indican que el modelo presenta problemas de generalización y de distribución de clases. Se recomienda balancear el conjunto de datos o aplicar técnicas de ponderación de clases, además de incorporar métodos de regularización (como *dropout* o *weight decay*) y un conjunto de prueba de mayor tamaño ($n > 100$) para obtener métricas más confiables. Finalmente, la aplicación de validación cruzada y el uso de early stopping antes del colapso observado en la época 2–3 podrían contribuir a mejorar la estabilidad y la capacidad de generalización del modelo.

Resultados y Discusion

En la comparación, el CNN presenta un aprendizaje estable: la pérdida desciende de forma sostenida y el *accuracy* se mantiene ~72–74% tanto en entrenamiento como en validación, con brecha mínima entre curvas. No obstante, el F1 se estabiliza en ~0.42–0.45, lo que evidencia dificultades para recuperar la clase minoritaria pese al uso de *class weights* y *augmentations*; el $\text{batch}=2$ y las estadísticas ruidosas de *BatchNorm* probablemente limitan la discriminación fina por clase.

El MIL, por su parte, alcanza picos de *train accuracy* más altos (~83%) y valida cerca de ~74%, pero muestra inestabilidad: el *validation loss* colapsa alrededor de las épocas 2–3 y la *val accuracy* oscila antes de estabilizarse. La matriz de confusión (6/0/1/3) revela sesgo hacia CE y un recall incompleto en LAA, típico de escenarios con etiquetas a nivel de bolsa y ruido de instancia (no todos los parches son informativos). Esto sugiere que el MIL ya está captando contexto por paciente, pero requiere mejor regularización y control del sobreajuste.

En síntesis, el CNN ofrece generalización consistente pero menor sensibilidad por clase, mientras que el MIL aporta capacidad de agregación a nivel paciente con riesgo de sobreajuste y sesgo de clase. Para converger, se recomienda: *split* estricto por paciente, sampler balanceado o Focal Loss, scheduler con *early stopping*, calibración de probabilidades y un MIL con *attention pooling* usando el CNN como extractor de *features*; con ello debería incrementarse el F1 de la clase minoritaria sin perder la estabilidad observada en el CNN.

Conclusión

Se concluye que ambos enfoques son viables y complementarios: el CNN es un *baseline* confiable para extraer representaciones a nivel de parche, y el MIL es prometedor para decisión clínica a nivel de paciente, siempre que se aborde el balanceo de clases, se incremente el tamaño del set de prueba, y se apliquen regularización y early stopping. Para la siguiente fase, se recomienda unificar: usar el CNN como extractor de *features* y un MIL con *attention pooling*, incorporar

samplers/focal loss, scheduler y calibración de probabilidades, y reportar métricas por clase y por paciente; el objetivo es elevar el F1 de la clase minoritaria manteniendo la estabilidad observada en el CNN.

Bibliografía

- He, K., Zhang, X., Ren, S., & Sun, J. (2016). **Deep Residual Learning for Image Recognition (ResNet)**. *CVPR*.
- Tan, M., & Le, Q. V. (2019). **EfficientNet: Rethinking Model Scaling for CNNs**. *ICML*.
- Ronneberger, O., Fischer, P., & Brox, T. (2015). **U-Net: Convolutional Networks for Biomedical Image Segmentation**. *MICCAI*.
- Dosovitskiy, A., et al. (2020). **An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale (ViT)**. *ICLR*.
- Ilse, M., Tomczak, J., & Welling, M. (2018). **Attention-based Deep Multiple Instance Learning**. *ICML*.
- Courtiol, P., et al. (2019). **Classification and Disease Localization in Histopathology Using Only Global Labels**. *Medical Image Analysis*, 58, 101550.
- Campanella, G., et al. (2019). **Clinical-grade Weakly Supervised Classification of Prostate Cancer in WSIs**. *Nature Medicine*, 25, 1301–1309.
- Litjens, G., et al. (2017). **A Survey on Deep Learning in Medical Image Analysis**. *Medical Image Analysis*, 42, 60–88.
- Kingma, D. P., & Ba, J. (2015). **Adam: A Method for Stochastic Optimization**. *ICLR*.
- Lin, T.-Y., et al. (2017). **Focal Loss for Dense Object Detection**. *ICCV*.
- Macenko, M., et al. (2009). **A Method for Normalizing Histology Slides for Quantitative Analysis**. *ISBI*.
- Tellez, D., et al. (2019). **Quantifying the Effects of Data Augmentation and Stain Color Normalization in CNNs for WSIs**. *Medical Image Analysis*, 58, 101544.